

说明书摘要

本发明属于 PET 成像领域，具体涉及一种基于先验图像的 PET 图像重建方法及 PET 图像 3D 感知方法。该方案将深度学习算法与既有的 PET 图像重建算法相结合，并将用户之前 PET 检查得到 PET 图像作为先验信息嵌入到神经网络中。最后，在受试者每次检查时，同时采用神经网络和 PET 图像重建算法根据传感器数据生成融合后的重建结果。本发明的 3D 感知方案利用 NeRF 中的点云采样技术获得 PET 图像对应的点云数据；然后通过自定义的编码方式将五维的点云数据转换为 2 维的新数据；最后训练生成对抗网络实现图像重建，进而利用生成的图像进行体积渲染得到 3D 感知。本发明可以解决现有 PET 成像的质量过度依赖探测器几何排列以及检测过程的数据规模的问题，并支持减少扫描时间和剂量。



权利要求书

1.一种基于先验图像的 PET 图像重建方法，其特征在于，其包括如下过程：

受试者在每次 PET 检查时采用相同的姿势进行扫描；

利用既有的 PET 图像重建算法根据受试者每次 PET 检查获得的多组传感器数据生成用于表征 PET 图像的多个第一强度矩阵 \mathbf{X}_1 ；

将受试者上次 PET 检查后获得 PET 图像作为先验数据集；通过先验数据集中的部分样本数据对一个 MLP 网络进行特征嵌入得到一个先验嵌入 MLP 网络；所述先验嵌入 MLP 网络输出的各个强度值与 PET 图像中的各个空间坐标一一对应；

结合既有的 PET 图像重建算法和所述先验嵌入 MLP 网络构建一个图像增强网络，所述先验嵌入 MLP 网络用于辅助所述 PET 图像重建算法重建出更清晰的 PET 图像；在图像增强网络中，所述 PET 图像重建算法和先验嵌入 MLP 网络分别根据输入的多组传感器数据生成对应的多个第一强度矩阵 \mathbf{X}_1 和多个第二强度矩阵 \mathbf{X}_2 ；所述图像增强网络将所述第一强度矩阵 \mathbf{X}_1 与所述第二强度矩阵 \mathbf{X}_2 进行融合，并利用融合后的增强矩阵 \mathbf{X} 重建出 PET 图像。

2.如权利要求 1 所述的基于先验图像的 PET 图像重建方法，其特征在于：在受试者第一次接受 PET 检查时，直接采用既有的 PET 图像重建算法根据获得的多组传感器数据生成用于表征 PET 图像中的多个第一强度矩阵 \mathbf{X}_1 ；然后基于第一强度矩阵 \mathbf{X}_1 重建出本次 PET 检查的 PET 图像；

或者，

在受试者第一次接受 PET 检查时，选择一个标准假体进行 PET 检查时获取的先验数据集对 MLP 模型进行特征嵌入；然后分别利用既有的 PET 图像重建算法和 MLP 模型基于受试者本次 PET 检查的传感器数据生成第一强度矩阵 \mathbf{X}_1 和第二强度矩阵 \mathbf{X}_2 ，并利用 \mathbf{X}_1 和 \mathbf{X}_2 融合后的增强矩阵 \mathbf{X} 重建出本次 PET 检查的 PET 图像。

3.如权利要求 1 所述的基于先验图像的 PET 图像重建方法，其特征在于：所述 MLP 网络实现特征嵌入的过程如下：

(1)根据先验数据集中各个重建出的 PET 图像，给定所有先验图像如下的坐标-强度对：

$$\{x_i, c_i^{pr}\}_{i=1}^N,$$

其中， i 表示图像空间场中的坐标索引； x_i 表示图像中的各个像素的空间位置； N 表示图像中的像素总数； c_i^{pr} 表示先验图像中第 i 个坐标点的强度值；

(2)通过最小化网络输出与先验图像强度之间的均方误差来优化 MLP 网络，将目标函

数设计如下：

$$\phi^* = \underset{\phi}{\operatorname{argmin}} \frac{1}{N} \sum_{i=1}^N \|M_{\phi}(x_i) - c_i^{pr}\|_2^2,$$

上式中， ϕ^* 表示满足优化目标的模型参数； $M_{\phi}(x_i)$ 表示由 MLP 网络模型预测出的第 i 个坐标点的强度值；

(3) 利用先验数据对 MLP 网络模型继续训练，训练过程中根据损失函数值不断调整网络参数，直到它能够准确地预测给定坐标点上的强度值。

4. 如权利要求 1 所述的基于先验图像的 PET 图像重建方法，其特征在于，在所述图像增强模型每次进行 PET 图像重建前，利用稀疏采样先验数据库中稀疏采样的稀疏数据完成网络训练；网络训练过程中以上一轮的先验嵌入 MLP 网络作为起点，通过集成成像系统的前向模型，训练网络来表示稀疏采样数据中的目标图像；并在其参数的函数空间中优化网络模型的参数；

其中，所述图像增强模型在训练阶段的优化目标如下：

$$\begin{cases} \theta^* = \operatorname{argmin}_{\theta} \|AM_{\theta} - y\|_2^2, \\ x^* : \{x_i, M_{\theta^*}(x_i)\}_{i=1}^N \end{cases}$$

上式中， θ^* 表示优化后的模型参数； θ 表示优化前的模型参数； x 代表要重建的图像； x^* 代表重建后的图像； y 代表传感器测定的 γ 光束数据；矩阵 A 代表成像系统的前向模型；定义数据项 $\epsilon(Ax, y)$ 用于衡量 Ax 和 y 之间的误差； $\rho(x)$ 是正则化项，用于表征通用的图像先验； M_{θ} 表示模型参数为 θ 的 MLP 网络； M_{θ^*} 表示模型参数为 θ^* 的 MLP 网络。

5. 一种基于神经辐射场的 PET 图像 3D 感知方法，其特征在于，其用于根据 PET 扫描时的传感器矩阵 K ，传感器姿态 ξ ，2D 采样模式 v ，以及重建出的部分 PET 图像，实现对 PET 扫描结果的 3D 感知；所述基于神经辐射场的 PET 图像 3D 感知方法包括如下步骤：

S1：采用神经辐射场中的点云采样技术根据已经重建出的多张 PET 图像得到表征受试者扫描部位的点云数据；点云数据包括各点的三维空间坐标以及对应的传感器矩阵 K 和传感器姿态 ξ ；

S2：将五维的点云数据降维成包含 3D 位置和角度信息的 2L 维数据，再利用预设的编码规则将 2L 维数据转换为包含密度标量 σ 和像素值 c 的 2 维数据；过程如下：

S21：定义一个表征物体的三维结构的形状编码 z_s ，其先验分布 p_s 满足标准高斯分布；定义一个表征坐标点的强度的外观编码 z_a ，以标准高斯分布作为其先验分布 p_a ；

S22: 通过如下的 $\gamma(p)$ 来表征 3D 采样的点云数据的 3D 位置 x 和视角方向 d , 进而得到位置函数 $\gamma(x)$ 和视角函数 $\gamma(d)$:

$$\gamma(p) = \dots, \cos(2^j \pi p), \sin(2^j \pi p), \dots,$$

S23: 将 3D 空间中一个点的位置 x 和物体的形状编码 z_s 结合起来, 生成一个中间变量 q , 即:

$$(\gamma(x), z_s) \mapsto q,$$

S24: 在中间变量 q 的基础上, 结合观察方向 d 和外观编码 z_a , 生成变量, 以预测最终的强度值 c , 即:

$$(q(x, z_s), \gamma(d), z_a) \mapsto c,$$

S25: 用位置 x 和形状编码 z_s 生成的中间变量 q 来预测该位置的体素密度 σ , 即:

$$q(x, z_s) \mapsto \sigma.$$

S3: 将编码阶段得到的 2 维数据与点云采样阶段得到的图像块 P_{real} 相互关联并作为样本数据, 利用包含大量样本数据的样本数据集对一个生成对抗网络进行训练, 得到一个可以根据 2 维数据生成任意视角下的图像块 P_{real} 的网络模型;

S4: 获取受试者 PET 扫描时重建出的有限的 PET 图像, 将其依次进行采样和编码后转换为 2 维数据, 然后输入到经过训练的生成对抗网络中, 根据所述生成对抗网络生成的数据对检查部位进行体积渲染, 并由生成器生成指定的任意视角下的新 PET 图像, 实现 3D 感知。

6. 如权利要求 5 所述的基于神经辐射场的 PET 图像 3D 感知方法, 其特征在于, 用于进行模型训练和体积渲染的 PET 图像采用如权利要求 1-4 中任意一项所述的基于先验图像的 PET 图像重建方法重建出的 PET 图像。

7. 如权利要求 5 所述的基于神经辐射场的 PET 图像 3D 感知方法, 其特征在于, 步骤 S1 中, 点云采样过程如下:

S11: 通过扫描过程的 2D 采样模式 v 来采样 PET 图像在成像过程中 γ 光束 R 在一个 $K \times K$ 个图像块 P_{real} 内的点; 完成 2D 采样;

S12: 利用下式定义射线采样过程中 $K \times K$ 的图像块 P_{real} 内的 2D 图像坐标 $P(u, s)$:

$$P(u, s) = \{(sx + u, sy + v) \mid x, y \in \{-\frac{K}{2}, \dots, \frac{K}{2} - 1\}\},$$

S13: 通过下式抽样 N 个沿着像素位置出发的 γ 光束 r 的 3D 点 \mathbf{x}_r^i , 并且按照在各个平面的投影排序, 以获得对于辐射场的数值积分, 进而完成 3D 采样:

$$t_i \sim U[t_n + \frac{i-1}{N}(t_f - t_n), t_n + \frac{i}{N}(t_f - t_n)],$$

上式中, t_i 表示光束上的各个采样点; U 表示采样方式; t_n 和 t_f 分别表示近边界和远边界;

S14: 获取 PET 图像重建采用的传感器数据中的传感器矩阵 K 和传感器姿态 ξ , 最终得到的点云数据包括三维空间坐标以及 K 和 ξ 。

8.如权利要求 5 所述的基于神经辐射场的 PET 图像 3D 感知方法, 其特征在于, 在步骤 S3 的生成对抗网络的训练过程中, 采用具有保持 JS 散度的特性的数据增强转换 T_k 对样本数据集进行数据增强; 其表达式如下:

$$JS(p_d^{T_k} \parallel p_g^{T_k}) = JS(p_d \parallel p_g),$$

上式中, $p_d^{T_k}$ 是变换后的训练数据分布, $p_g^{T_k}$ 是由生成器经过相同增强变换后捕获的分布; p_d 是原训练数据分布, p_g 是由生成器捕获的分布;

且/或

步骤 S3 中生成对抗网络在训练阶段采用损失函数 $L(\theta, \{\phi_k\})$ 为:

$$\begin{cases} L(\theta, \{\phi_k\}) = L(\theta, \phi_0) + \frac{\lambda}{n-1} \sum_{i=1}^k L(\theta, \phi_k) \\ L(\theta, \phi_k) = \mathbf{E}_{z_s \sim p_s, z_a \sim p_a, \xi \sim p_\xi, v \sim p_v} [f(D_\phi(G_\theta(z_s, z_a, \xi, v)))] + \mathbf{E}_{I \sim p_D, v \sim p_v} [f(-D_\phi(I, v))] + L_r \\ L_r = E_{f \sim D(p), p \sim P} \left[\frac{1}{whd} \phi_i(G(p)) - \phi_i(T(p)) \right]_2 \end{cases}$$

上式中, L_r 表示鉴别器损失; G_θ 表示生成器; D_ϕ 表示判别器; $\phi_i(\cdot)$ 表示预训练的深度学习神经网络的第 i 层输出; w, h, d 分别代表一个特征空间的宽度、高度和深度; G 是 D_ϕ 对中间特征图 f 的处理; 而 T 是对真实图像块 p 的处理; $D(p)$ 表示解码图像块的分布; P 是真实图像数据的分布; I 表示真实图像; 函数 $f(\cdot)$ 为 $f(u) = \max(0, 1+u)$ 。

9.如权利要求 5 所述的基于神经辐射场的 PET 图像 3D 感知方法, 其特征在于: 在步骤 S4 的体积渲染阶段采用的损失函数 L_{gen} 如下:

$$\begin{cases} L_{gen} = \lambda_1 L_r(Net) + \lambda_2 L_{MSE}(G) + \lambda_3 L_{NLL}(z_s, z_a) \\ L_{MSE}(G) = \frac{1}{N} \sum_{i=1}^N (I_i - G_i)^2 \\ L_{NLL}(z_s, z_a) = -\frac{1}{N} \sum_{i=1}^N \log \log p(p_s | z_s, p_a | z_a) \end{cases}$$

上式中, $L_r(Net)$ 为与选取的深度学习神经网络有关模型损失, $L_{MSE}(G)$ 为生成器的均方误差损失; $L_{NLL}(z_s, z_a)$ 为负对数似然损失; λ_1 、 λ_2 和 λ_3 分别为各类损失的权重; I_i 表示第 i 个真实图像; G_i 表示第 i 个生成图像。

10. 一种 PET 数据处理设备, 其特征在于, 其采用如权利要求 1-4 中任意一项所述的基于先验图像的 PET 图像重建方法, 利用受试者的 PET 扫描数据重建对应的 PET 图像;
且/或

所述数据处理设备采用如权利要求 5-9 中任意一项所述的基于神经辐射场的 PET 图像 3D 感知方法, 结合 PET 扫描数据和重建出的部分视角下 PET 图像生成指定的任意视角下的新的 PET 图像, 进而实现 3D 感知。

说明书

基于先验图像的 PET 图像重建方法及 PET 图像 3D 感知方法

技术领域

本发明属于 PET 成像领域，具体涉及一种基于先验图像的 PET 图像重建方法、基于神经辐射场的 PET 图像 3D 感知方法、以及对应的 PET 数据处理设备。

背景技术

正电子发射断层成像（Positron Emission Tomography, PET）是一种重要的放射性核素显像技术，它通过注入含有放射性标记（例如 ^{18}F ）的示踪剂到患者体内，来观察活体内的生物化学过程。示踪剂在衰变时释放正电子，这些正电子与电子相遇后湮灭，产生 511keV 的 γ 光子对。PET 扫描仪会探测 γ 射线，并通过计算机重建出示踪剂在身体内的三维分布图像。这一技术在癌症、心脏病和脑部疾病的诊断中尤其重要，它能够展示体内代谢活动的变化，如代谢旺盛的癌细胞在 PET 图像上会显得更亮。同时，PET 在神经科学和药理学研究中有广泛应用，它能揭示药物在大脑中的分布和大脑的能量消耗模式。通过检测代谢过程中产生的 γ 光子，PET 能提供血流状况、新陈代谢率、受体活动和基因表达等关键生物学信息，对于早期筛查脑部疾病和研究病理机制具有显著价值。

然而，PET 的空间分辨率较低，可能无法清晰地显示微小的病变或细节。此外，PET 的成本高昂，且设备和操作的可获取性受限。在图像质量方面，尤其是在低剂量条件下，噪声和伪影可能影响图像解读的准确性。患者在扫描过程中的微小运动也可能导致图像模糊，增加了在低辐射剂量下提升 PET 图像质量的技术难度。此外，由于放射性物质的使用，患者需承受一定程度的辐射暴露，对于儿童等特殊人群，为确保安全，需在较低剂量下长时间扫描来累积足够光子计数，这将会进一步增大噪声。因此，改进 PET 技术以降低辐射风险并提高图像质量，是当前医学成像领域面临的重要挑战之一。

同时，在癌症等慢性疾病的治疗和康复过程中，患者可能需要多次接受 PET 成像来辅助临床诊断或监测治疗效果。当前的 PET 技术不能将先验信息结合，导致每次 PET 成像成本高，耗时长，并且患者都要承受一定剂量的放射性辐射影响。

此外，在三维 PET 成像中，由于数据稀疏性，面临着构建图像的诸多挑战，包括相对较低的信噪比、有限的空间分辨率限制了对微小病变和细节的捕获能力。此外，患者的呼吸、心跳及其他身体活动可能引入运动伪影，造成图像模糊或错误的解剖结构表示。在不同组织类型之间实现图像的均匀性和高对比度也颇具挑战，同时探测器的性能和排列方式对图像质

量有着直接影响。为了解决这些问题，往往需要开发更高效的探测器、先进的重建算法和图像处理技术。但这些途径往往成本巨大，技术要求高。

同时，在临床诊断中，医生往往需要 3D 感知图像来辅助诊断，准确判断病灶区域与位置，然而，现在的三维 PET 重建技术，往往采用线性插值等方法获得连续表示，这种方法获得的 3D 感知图像往往难以达到很高的精度，在辅助诊断过程中难以发挥作用。在深度学习领域的神经辐射场（Neural Radiance Fields, NeRF）能够有效的解决这一问题。该技术是一个近年来提出的用于估计三维体积场景表示的模型。它通过神经网络参数化场景的辐射场和密度，能学习从不同角度合成新视图。NeRF 通过体积渲染技术，从沿着光线投射的点样本生成新的视图。NeRF 能够从一系列 2D 图像中学习并重建出高度逼真的 3D 场景，包括复杂的光照和遮挡效果，这与 PET 成像中解剖结构的重叠等问题类似，对于高质量的 PET 图像重建非常有用。但是基于 NeRF 的 3D 感知技术仍然非常依赖样本图像的质量和数量。

综上所述，在现有的 PET 成像技术中，为了降低图像噪声、消除伪影干扰，得到更高质量的图像，往往需要在设备中采用更紧密的传感器布局，在检查过程中提高辐射剂量，进而获得更大规模的传感器数据，而这些不仅会提高成本还会对受试者的健康造成危害。如何在 PET 数据质量和安全性间保持平衡，仍需要技术人员付出努力。

发明内容

为了解决现有 PET 成像技术中，图像重建和 3D 感知过程的图像质量过度依赖探测器几何排列以及检测过程的数据规模的问题，本发明提供一种基于先验图像的 PET 图像重建方法、基于神经辐射场的 PET 图像 3D 感知方法、以及对应的 PET 数据处理设备。

本发明采用以下技术方案实现：

一种基于先验图像的 PET 图像重建方法，其包括如下过程：

受试者在每次 PET 检查时采用相同的姿势进行扫描。

利用既有的 PET 图像重建算法根据受试者每次 PET 检查获得的多组传感器数据生成用于表征 PET 图像中的多个第一强度矩阵 \mathbf{X}_1 。

将受试者上次 PET 检查后获得 PET 图像作为先验数据集。通过先验数据集中的部分样本数据对一个 MLP 网络进行特征嵌入得到一个先验嵌入 MLP 网络。先验嵌入 MLP 网络输出的各个强度值与 PET 图像中的各个空间坐标一一对应。

结合既有的 PET 图像重建算法和先验嵌入 MLP 网络构建一个图像增强网络。先验嵌入 MLP 网络用于辅助 PET 图像重建算法重建出更清晰的 PET 图像。在图像增强网络中，PET 图像重建算法和先验嵌入 MLP 网络分别根据输入的多组传感器数据生成对应的多个第一强

度矩阵 \mathbf{X}_1 和多个第二强度矩阵 \mathbf{X}_2 ；图像增强网络将第一强度矩阵 \mathbf{X}_1 与第二强度矩阵 \mathbf{X}_2 进行融合，并利用融合后的增强矩阵 \mathbf{X} 重建出 PET 图像。

作为本发明进一步的改进，在受试者第一次接受 PET 检查时，直接采用既有的 PET 图像重建算法根据获得的多组传感器数据生成用于表征 PET 图像中的多个第一强度矩阵 \mathbf{X}_1 ；然后基于第一强度矩阵 \mathbf{X}_1 重建出本次 PET 检查的 PET 图像。

或者，

在受试者第一次接受 PET 检查时，选择一个标准假体进行 PET 检查时获取的先验数据集对 MLP 模型进行特征嵌入。然后分别利用既有的 PET 图像重建算法和 MLP 模型基于受试者本次 PET 检查的传感器数据生成第一强度矩阵 \mathbf{X}_1 和第二强度矩阵 \mathbf{X}_2 ，并利用 \mathbf{X}_1 和 \mathbf{X}_2 融合后的增强矩阵 \mathbf{X} 重建出本次 PET 检查的 PET 图像。

作为本发明进一步的改进，MLP 网络实现特征嵌入的过程如下：

(1) 根据先验数据集中各个重建出的 PET 图像，给定所有先验图像如下的坐标-强度对：

$$\{x_i, c_i^{pr}\}_{i=1}^N,$$

其中， i 表示图像空间场中的坐标索引； x_i 表示图像中的各个像素的空间位置； N 表示图像中的像素总数； c_i^{pr} 表示先验图像中第 i 个坐标点的强度值。

(2) 通过最小化网络输出与先验图像强度之间的均方误差来优化 MLP 网络，将目标函数设计如下：

$$\phi^* = \operatorname{argmin}_{\phi} \frac{1}{N} \sum_{i=1}^N \|M_{\phi}(x_i) - c_i^{pr}\|_2^2,$$

上式中， ϕ^* 表示满足优化目标的模型参数； $M_{\phi}(x_i)$ 表示由 MLP 网络模型预测出的第 i 个坐标点的强度值。

(3) 利用先验数据对 MLP 网络模型继续训练，训练过程中根据损失函数值不断调整网络参数，直到它能够准确地预测给定坐标点上的强度值。

作为本发明进一步的改进，在图像增强模型每次进行 PET 图像重建前，利用稀疏采样先验数据库中稀疏采样的稀疏数据完成网络训练；网络训练过程中以上一轮的先验嵌入 MLP 网络作为起点，通过集成成像系统的前向模型，训练网络来表示稀疏采样数据中的目标图像；并在其参数的函数空间中优化网络模型的参数。

其中，图像增强模型在训练阶段的优化目标如下：

$$\begin{cases} \theta^* = \operatorname{argmin}_{\theta} \|AM_{\theta} - y\|_2^2, \\ x^* : \{x_i, M_{\theta^*}(x_i)\}_{i=1}^N \end{cases}$$

上式中, θ^* 表示优化后的模型参数; θ 表示优化前的模型参数; x 代表要重建的图像; x^* 代表重建后的图像; y 代表传感器测定的 γ 光束数据; 矩阵 A 代表成像系统的前向模型; 定义数据项 $\varepsilon(Ax, y)$ 用于衡量 Ax 和 y 之间的误差; $\rho(x)$ 是正则化项, 用于表征通用的图像先验; M_{θ} 表示模型参数为 θ 的 MLP 网络; M_{θ^*} 表示模型参数为 θ^* 的 MLP 网络。

本发明还包括一种基于神经辐射场的 PET 图像 3D 感知方法, 其用于根据 PET 扫描时的传感器矩阵 K , 传感器姿态 ξ , 2D 采样模式 v , 以及重建出的部分 PET 图像, 实现对 PET 扫描结果的 3D 感知。基于神经辐射场的 PET 图像 3D 感知方法包括如下步骤:

S1: 采用神经辐射场中的点云采样技术根据已经重建出的多张 PET 图像得到表征受试者扫描部位的点云数据; 点云数据包括各点的三维空间坐标以及对应的传感器矩阵 K 和传感器姿态 ξ 。

S2: 将五维的点云数据降维成包含 3D 位置和角度信息的 2L 维数据, 再利用预设的编码规则将 2L 维数据转换为包含密度标量 σ 和像素值 c 的 2 维数据。过程如下:

S21: 定义一个表征物体的三维结构的形状编码 z_s , 其先验分布 p_s 满足标准高斯分布; 定义一个表征坐标点的强度的外观编码 z_a , 以标准高斯分布作为其先验分布 p_a 。

S22: 通过如下的函数 $\gamma(p)$ 来表征 3D 采样的点云数据的 3D 位置 x 和视角方向 d , 进而得到位置函数 $\gamma(x)$ 和视角函数 $\gamma(d)$:

$$\gamma(p) = \cdots, \cos(2^j \pi p), \sin(2^j \pi p), \cdots。$$

S23: 将 3D 空间中一个点的位置 x 和物体的形状编码 z_s 结合起来, 生成一个中间变量 q , 即:

$$(\gamma(x), z_s) \mapsto q。$$

S24: 在中间变量 q 的基础上, 结合观察方向 d 和外观编码 z_a , 生成变量, 以预测最终的强度值 c , 即:

$$(q(x, z_s), \gamma(d), z_a) \mapsto c。$$

S25: 用位置 x 和形状编码 z_s 生成的中间变量 q 来预测该位置的体素密度 σ , 即:

$$q(x, z_s) \mapsto \sigma。$$

S3: 将编码阶段得到的 2 维数据与点云采样阶段得到的图像块 P_{real} 相互关联并作为样本

数据，利用包含大量样本数据的样本数据集对一个生成对抗网络进行训练，得到一个可以根据 2 维数据生成任意视角下的图像块 P_{real} 的网络模型。

S4: 获取受试者 PET 扫描时重建出的有限的 PET 图像，将其依次进行采样和编码后转换为 2 维数据，然后输入到经过训练的生成对抗网络中，根据所述生成对抗网络生成的数据对检查部位进行体积渲染，并由生成器生成指定的任意视角下的新 PET 图像，实现 3D 感知。

作为本发明进一步的改进，用于进行模型训练和体积渲染的 PET 图像采用如前述的基于先验图像的 PET 图像重建方法重建出的 PET 图像。

作为本发明进一步的改进，步骤 S1 中，点云采样过程如下：

S11: 通过扫描过程的 2D 采样模式 v 来采样 PET 图像在成像过程中 γ 光束 R 在一个 $K \times K$ 个图像块 P_{real} 内的点，完成 2D 采样。

S12: 利用下式定义射线采样过程中 $K \times K$ 的图像块 P_{real} 内的 2D 图像坐标 $P(u, s)$ ：

$$P(u, s) = \{(sx + u, sy + v) \mid x, y \in \{-\frac{K}{2}, \dots, \frac{K}{2} - 1\}\}。$$

S13: 通过下式抽样 N 个沿着像素位置出发的 γ 光束 r 的 3D 点 \mathbf{x}_r^i ，并且按照在各个平面的投影排序，以获得对于辐射场的数值积分，进而完成 3D 采样：

$$t_i \sim U[t_n + \frac{i-1}{N}(t_f - t_n), t_n + \frac{i}{N}(t_f - t_n)]$$

上式中， t_i 表示光束上的各个采样点； t_n 和 t_f 分别表示近边界和远边界。

S14: 获取 PET 图像重建采用的传感器数据的传感器矩阵 K 和传感器姿态 ξ ，最终得到的点云数据包括三维空间坐标以及 K 和 ξ 。

作为本发明进一步的改进，在步骤 S3 的生成对抗网络的训练过程中，采用具有保持 JS 散度的特性的数据增强转换 T_k 对样本数据集进行数据增强；其表达式如下：

$$JS(p_d^{T_k} \parallel p_g^{T_k}) = JS(p_d \parallel p_g)$$

上式中， $p_d^{T_k}$ 是变换后的训练数据分布， $p_g^{T_k}$ 是由生成器经过相同增强变换后捕获的分布； p_d 是原训练数据分布， p_g 是由生成器捕获的分布。

且/或

步骤 S3 中生成对抗网络在训练阶段采用损失函数 $L(\theta, \{\phi_k\})$ 为：

$$\begin{cases} L(\theta, \{\phi_k\}) = L(\theta, \phi_0) + \frac{\lambda}{n-1} \sum_{i=1}^k L(\theta, \phi_k) \\ L(\theta, \phi_k) = \mathbf{E}_{z_s \sim p_s, z_a \sim p_a, \xi \sim p_\xi, v \sim p_v} [f(D_\phi(G_\theta(z_s, z_a, \xi, v)))] + \mathbf{E}_{I \sim p_D, v \sim p_v} [f(-D_\phi(I, v))] + L_r \\ L_r = \mathbf{E}_{f \sim D(p), p \sim P} \left[\frac{1}{whd} \phi_i(G(p)) - \phi_i(T(p)) \right]_2 \end{cases}$$

上式中， L_r 表示鉴别器损失； G_θ 表示生成器； D_ϕ 表示判别器； $\phi_i(\cdot)$ 表示预训练的深度学习神经网络的第 i 层输出； w, h, d 分别代表一个特征空间的宽度、高度和深度； G 是 D_ϕ 对中间特征图 f 的处理；而 T 是对真实图像块 p 的处理； $D(p)$ 表示解码图像块的分布； P 是真实图像数据的分布； I 表示真实图像；其中，函数 $f(\cdot)$ 为 $f(u) = \max(0, 1+u)$ 。

作为本发明进一步的改进，在步骤 S4 的体积渲染阶段采用的损失函数 L_{gen} 如下：

$$\begin{cases} L_{gen} = \lambda_1 L_r(Net) + \lambda_2 L_{MSE}(G) + \lambda_3 L_{NLL}(z_s, z_a) \\ L_{MSE}(G) = \frac{1}{N} \sum_{i=1}^N (I_i - G_i)^2 \\ L_{NLL}(z_s, z_a) = -\frac{1}{N} \sum_{i=1}^N \log \log p(p_s | z_s, p_a | z_a) \end{cases}$$

上式中， $L_r(Net)$ 为与选取的深度学习神经网络有关模型损失， $L_{MSE}(G)$ 为生成器的均方误差损失； $L_{NLL}(z_s, z_a)$ 为负对数似然损失； λ_1 、 λ_2 和 λ_3 分别为各类损失的权重； I_i 表示第 i 个真实图像； G_i 表示第 i 个生成图像。

本发明还包括一种 PET 数据处理设备，该数据处理设备采用如前述的基于先验图像的 PET 图像重建方法，利用受试者的 PET 扫描数据重建对应的 PET 图像；

且/或

所述数据处理设备还采用如前述的基于神经辐射场的 PET 图像 3D 感知方法，结合 PET 扫描数据和重建出的部分视角下 PET 图像生成指定的任意视角下的新的 PET 图像，进而实现 3D 感知。

本发明提供的技术方案，具有如下的有益效果：

本发明提供的 PET 图像重建算法引入受试者前次检查结果作为先验信息，并将先验信息与传感器数据结合实现成像，进而可以在低剂量的诊疗过程中实现更高质量的 PET 成像效果。降低用户多次检查过程中遭受的损伤。本发明还将深度学习中的神经辐射场应用于 PET 成像，并结合 GAN 的以图生图性能实现根据少量重建出的 PET 图像生成全方位的出 PET 图像 3D 感知。最终得到的经过训练的网络模型可以根据输入的传感器数据和少量 PET

图像输出任意角度的 PET 图像切片，辅助医生诊断。

由于本发明改进后的图像重建和 3D 感知技术可以不依赖大规模的传感器数据和 PET 图像，因此该方案在实际应用中至少还具有以下优点：

1、低剂量成像：在多次 PET 成像中，依赖第一次成像，可以用较低的剂量得到较好的成像效果。

2、高隐私性：不需要来自外部受试者的训练数据来开发网络，注重对患者的隐私保护。

3、高准确度：通过多次 PET 扫描，可以准确重建小而详细的变化，如解剖结构、肿瘤进展等，将有利于临床诊断和治疗。

4、较强的场景适应性：广泛适用于不同的身体部位和不同的患者。对于 PET 图像，通常会对患者进行多次扫描以进行临床诊断或治疗随访，以制定治疗计划或监测治疗前后肿瘤体积的变化。在纵向图像序列中，以前的扫描可以提供有用的先验知识。

5、更准确的 3D 感知：本发明的 3D 感知可以获得任意角度的 PET 图像切片，使得医护人员能更清晰地区分接近的结构，特别是在小病灶的检测上更为有效。有助于医护人员更准确地识别和定位病变，尤其是在复杂的器官结构中。

附图说明

图 1 为现有重建算法迭代生成 PET 图像的原理示意图。

图 2 为本发明实施例 1 中提供的基于先验图像的 PET 图像重建方法的原理示意图。

图 3 为本发明实施例 2 中提供的基于神经辐射场的 PET 图像 3D 感知方法的原理示意图。

图 4 为本发明实施例 2 中提供的基于神经辐射场的 PET 图像 3D 感知方法的步骤流程图。

图 5 为本发明实施例 2 中采用的基于 NeRF 的 PET 图像采样的原理图。

图 6 为本发明实施例 2 中采用的基于 NeRF 的 3D 采样的原理图。

图 7 为本发明实施例 2 中采用的自定义的点云数据编码的原理示意图。

图 8 采用环形布局的 PET 设备中的传感器位置分布图。

图 9 采用平行板布局的 PET 设备中的传感器位置分布图。

具体实施方式

为了使本发明的目的、技术方案及优点更加清楚明白，以下结合附图及实施例，对本发明进行进一步地详细说明。应当理解，此处所描述的具体实施例仅用以解释本发明，并不用于限定本发明。

实施例 1

在现有的 PET 成像技术中，PET 设备前端的传感器部分在每次运行时可以获得大量的

传感器数据，而后端的数据处理部分则采用 FBP，MLEM，OSEM 等既有的重建算法对传感器数据进行迭代运算，进而生成对应 2D 的 PET 图像。该过程的原理大致如图 1 所示。在这类传统方案中，为了适应不同用户的检查需要，设备的数据处理部分针对每个受试者进行检查时，都会对数据处理部分的算法进行初始化，以保障最终重建结果的准确性。此外，该方案还要求受试者在每次检查过程都必须承受足够水平的辐射伤害。

在此基础上，本实施例提供一种基于先验图像的 PET 图像重建方法，该方法是一种面向收拾者个体的图像重建方案。考虑到每个用户在接受检查时通常处于某种特定疾病（通常是癌症）的治疗阶段，因而需要再一段时期后对同一部位进行重复检查。如图 2 所示，本实施例将基于深度学习的神经网络与既有的 PET 图像重建算法相结合，并将同一用户在上一次 PET 检查过程中得到 PET 图像作为先验信息嵌入到神经网络中。最后，在受试者每次检查时，同时采用神经网络和 PET 图像重建算法根据传感器数据生成融合后的重建结果。

对于同一用户来说，相邻两次检查的结果往往具有高度相关性，神经网络利用先验信息可以有效学习到 PET 图像中大量特征。因此在采用这种技术后，一方面，将神经网络学习到的该特征与既有 PET 图像重建算法生成的结果融合后，可以显著提高重建出的 PET 图像的质量。另一方面，医技人员还可以逐次降低同一用户接受后续检查时的辐射剂量和检查时长，达到利用稀疏采样数据生成原方案同等图像质量的目的，进而降低 PET 检查对用户健康的危害。

具体地，本实施例提供的基于先验图像的 PET 图像重建方法如下特点：

一、新方案对受试者接受检查过程的要求

由于本实施例的方案需要将同一受试者在先检查的结果作为在后检查结果的先验图像，并嵌入到神经网络，因此用户在每次检查时需要在医技人员的帮助下保持相同姿势接受 PET 设备的扫描。

二、新方案的模型架构

本实施例结合既有的 PET 图像重建算法和先验嵌入 MLP 网络构建一个图像增强网络，图像增强网络用于根据输入的传感器数据重建出对应的 PET 图像。该方案中，既有的 PET 图像重建算法作为 MLP 网络的一个组件。本实施例虽然增加了神经网络的图像生成路径，但是仍然需要采用既有 PET 图像重建算法参与图像重建，既有 PET 图像重建算法在新方案中的作用主要包括两点：一是在受试者首次接受检查时，独立或共同生成 PET 图像，二是在受试者后续检查过程生成 PET 图像的“基准”，以便神经网络结合先验信息对基准 PET 图像进行“增强”。

在受试者每次 PET 检查时，既有的 PET 图像重建算法根据获得的多组传感器数据生成用于表征 PET 图像中的多个第一强度矩阵 \mathbf{X}_1 ；第一强度矩阵中的各个元素即为 PET 图像中各个像素的强度值。

在图像增强网络中，PET 图像重建算法和先验嵌入 MLP 网络分别根据输入的多组传感器数据生成对应的多个第一强度矩阵 \mathbf{X}_1 和多个第二强度矩阵 \mathbf{X}_2 ；图像增强网络将第一强度矩阵 \mathbf{X}_1 与第二强度矩阵 \mathbf{X}_2 进行融合，并利用融合后的增强矩阵 \mathbf{X} 重建出 PET 图像。

三、先验图像的嵌入

利用受试者上次 PET 检查后获得多组传感器数据和相关联的多张重建出的 PET 图像构成一个先验数据集。通过先验数据集中的部分样本数据对一个 MLP 网络进行特征嵌入，进而得到一个能够根据输入的传感器数据输出多个强度值的先验嵌入 MLP 网络。先验嵌入 MLP 网络输出的各个强度值与 PET 图像中的各个空间坐标一一对应。

先验图像的嵌入本质上就是将空间坐标映射到先前图像的强度值，有效地将这些信息编码到网络的参数中。通过一个基于坐标的多层感知器(Multi-Layer Perceptron Network, MLP)网络，将空间坐标 \mathbf{x} 映射到先验图像 \mathbf{x}^{pr} 中对应的强度值 \mathbf{c} 。映射过程如下：

$$M_{\theta} : x_i \rightarrow c_i^{pr}$$

其中， M_{θ} 表示 MLP 模型； i 表示图像空间场中的坐标索引； x_i 表示图像中的各个像素的空间位置； N 表示图像中的像素总数； c_i^{pr} 表示先验图像中第 i 个坐标点的强度值。

通过上述映射过程可以给定所有在先验图像中的坐标-强度对：

$$\{x_i, c_i^{pr}\}_{i=1}^N,$$

在此基础上，本实施例可以随机初始化一个 MLP 模型。当然，在任意用户初次接受检查时，也可以根据模拟的假体在检查得到的 PET 数据来初始化一个 MLP 模型。

通过最小化网络输出与先验图像强度之间的均方误差来优化 MLP 网络。优化的目标是调整网络参数，直到它能够准确地预测给定坐标点上强度值。这一优化可以通过下式来表示：

$$\phi^* = \underset{\phi}{\operatorname{argmin}} \frac{1}{N} \sum_{i=1}^N \|M_{\phi}(x_i) - c_i^{pr}\|_2^2,$$

上式中， ϕ^* 表示满足优化目标的模型参数； $M_{\phi}(x_i)$ 表示由 MLP 网络模型预测出的第 i 个坐标点的强度值。

优化完成后，先验图像 \mathbf{x}^{pr} 的内部信息就被编码到了 MLP 网络 M_{ϕ^*} 中，对应网络参数 ϕ^* 。使得 MLP 网络 M_{ϕ^*} 成为先验图像 \mathbf{x}^{pr} 的一个表示。为了清晰可见，之后使用 \mathbf{M}^{pr} 来表示嵌入了先验信息的 MLP 网络，即：

$$x^{pr} = M_{\phi^*} = M^{pr}。$$

四、稀疏数据的网络训练

在图像增强模型每次进行 PET 图像重建前，利用稀疏采样先验数据库中稀疏采样的稀疏数据完成网络训练；网络训练过程中以上一轮的先验嵌入 MLP 网络作为起点，通过集成成像系统的前向模型，训练网络来表示稀疏采样数据中的目标图像；并在其参数的函数空间中优化网络模型的参数。

本实施例中，用 x 代表要重建的图像， x^* 代表优化问题的解，即重建后的图像。用 y 代表传感器测定的 γ 光束数据，矩阵 A 代表成像系统的前向模型。定义数据项为 $\varepsilon(Ax, y)$ ，用于衡量 Ax 和 y 之间的误差，可以选用 L1 范数或 L2 范数来计算。由此，优化目标可以定义为如下公式：

$$x^* = \underset{x}{\operatorname{argmin}} \varepsilon(Ax, y) + \rho(x)$$

其中， $\rho(x)$ 是正则化项，用于表征通用的图像先验，它通常用于解决数据不完整的情况下的图像重建正则化项引入了额外的信息，有总变分 (Total Variation, TV)，L1 范数，L2 范数等可以选择。

将空间坐标映射到先前图像的强度值，有效地将这些信息编码到网络的参数中。具体来说，利用先前嵌入到 MLP 模型中的先验信息 M^{pr} 和传感器测量值 y ，来学习目标图像的神经表征。未知目标图像 x 由基于坐标的 MLP 模型 M_{θ} 来进行参数化，其中 θ 为网络参数。同时，数据项被定义为 $\min_x \varepsilon(Ax, y) = \min_{\theta} \varepsilon(AM_{\theta}, y)$ ，优化转化为在 MLP 参数空间进行。用从先验图像和神经网络参数化中获得的隐式先验 $\rho(x)$ 替代了显式正则化项，即先前图像在 M^{pr} 中嵌入的内部信息以及由神经网络参数化 M_{θ} 捕获的低级图像统计先验。特定的隐式正则化意味着所有坐标-强度对共享同一由 MLP 网络参数化的底层连续函数。由此可以将优化目标公式化如下：

$$\theta^* = \underset{\theta}{\operatorname{argmin}} \varepsilon(AM_{\theta}, y; M^{pr}) \quad x^* = M_{\theta^*}$$

本实施例中，MLP 模型 M_{θ} 通过最小化 L2 范数损失进行训练，该损失由先验嵌入网络 M^{pr} 初始化，即：

$$\theta^* = \underset{\theta}{\operatorname{argmin}} \|AM_{\theta} - y\|_2^2 \quad x^* = M_{\theta^*}$$

其中，矩阵 A 代表着不同的 PET 图像重建方法，比如 FBP，MLEM，OSEM 等。

五、PET 图像重建

经过训练的图像增强网络已经实现了先验嵌入，因而可以根据输入的传感器数据生成融

合后的增强矩阵 \mathbf{X} 。由于被训练的网络可以推断出图像的所有空间坐标上的强度值，即：

$$\{x_i, M_{\theta^*}(x_i)\}_{i=1}^N$$

因此，在图像网格的所有坐标上填充强度值，就构成了最终的重建 PET 图像 x^* 。该过程可以用如下公式表达：

$$x^* : \{x_i, M_{\theta^*}(x_i)\}_{i=1}^N$$

也可以简单表达为：

$$x^* = M_{\theta^*}。$$

结合前文内容可知，在采用传统重建算法的方案中，任意用户的任意一次检查对于 PET 设备的数据处理部分来说处理过程都是一样的，设备并不需要获取受试者的历史检查数据，也不区分受试者的检查次数。而在本实施例方案中，由于 PET 图像每次重建时需要利用当前用户在上一次检查时获得图像数据作为先验信息，因此需要对受试者的身份进行识别，并获取受试者的历史检查数据。考虑到用户在第一次进行 PET 扫描时是缺乏有效的先验信息的，本实施例方案还做出如下规定：

在受试者第一次接受 PET 检查时，直接采用既有的 PET 图像重建算法根据获得的多组传感器数据生成用于表征 PET 图像中的多个第一强度矩阵 \mathbf{X}_1 ；然后基于第一强度矩阵 \mathbf{X}_1 重建出本次 PET 检查的 PET 图像。即：受试者第一次接受检查时不进行先验嵌入，直接采用与传统方案相同的数据处理方式获取重建出的 PET 图像。

或者，在其他方案中，还可以选择一个标准的假体的检查数据作为当前用户先验信息，在受试者第一次接受 PET 检查时，利用标准假体的先验数据集对 MLP 模型进行特征嵌入。然后分别利用既有的 PET 图像重建算法和 MLP 模型基于受试者本次 PET 检查的传感器数据生成第一强度矩阵 \mathbf{X}_1 和第二强度矩阵 \mathbf{X}_2 ，并利用 \mathbf{X}_1 和 \mathbf{X}_2 融合后的增强矩阵 \mathbf{X} 重建出本次 PET 检查的 PET 图像。即：受试者第一次接受检查时采用公共数据进行先验嵌入，并基于改进后的方案获得重建出的 PET 图像。

实施例 2

在实施例 1 方案的基础上，本实施例进一步提供一种基于神经辐射场的 PET 图像 3D 感知方法，其用于根据 PET 扫描时的传感器矩阵 K ，传感器姿态 ξ ，2D 采样模式 v ，以及重建出的部分 PET 图像，实现对 PET 扫描结果的 3D 感知。

如图 3 所示，本实施的方案首先利用神经辐射场（Neural Radiance Fields, NeRF）中的点云采样技术根据已经重建出的多张 PET 图像得到表征受试者扫描部位的点云数据。然后通

过自定义的编码方式将五维的点云数据转换为 2L 维的新数据。再结合 2L 维的新数据对生成对抗网络(Generative Adversarial Network, GAN)进行训练, 使得生成对抗网络具有根据有限角度的 PET 图像生成任意角度的新图像的性能。最后利用完成训练的生成对抗网络生成指定的任意视角的 PET 图像, 实现 PET 图像的 3D 感知。

其中, 生成对抗网络包含生成器 G_θ 和鉴别器 D_ϕ , 生成器以相机矩阵 K , 相机姿态 ξ , 2D 采样模式 \mathbf{v} 和形状/外观编码 $\mathbf{z}_s \in R^m$, $\mathbf{z}_a \in R^n$ 作为输入, 并预测出一个图像块 P_{pred} 。鉴别器将合成的图像块 P_{pred} 与从真实图像 I 中提取的图像块 P_{real} 进行比较。在经过训练后, 生成对抗网络可以在推理时准确预测每个图像像素的强度值。考虑到在训练时, 如果仅仅利用 GAN 实现 3D 感知的代价太高。因此, 本实施例的时机方案将 NeRF 与 GAN 结合, 并将全图预测调整为仅预测固定大小的 $K \times K$ 像素块, 它随机缩放和旋转来为整个辐射度场提供梯度。

详细地, 如图 4 所示, 本实施例提供的基于神经辐射场的 PET 图像 3D 感知方法包括如下步骤:

S1: 采用神经辐射场中的点云采样技术根据已经重建出的多张 PET 图像得到表征受试者扫描部位的点云数据。采样生成的点云数据包括各点的三维空间坐标以及对应的传感器矩阵 K 和传感器姿态 ξ 。

在本实施例中, 点云采样过程包括 2D 采用和 3D 采样两个阶段, 过程具体如下:

S11: PET 扫描的传感器数据中的 2D 采样模式的格式为: $\mathbf{v} = (u, s)$ 。其中, u 代表 2D 图像平面上的一个点的归一化坐标。 s 表示该点在 PET 成像场景中的某种尺度或深度信息。由此向量 \mathbf{v} 可以表示一个在 3D 空间中的具体点, 它结合了 2D 平面的位置和深度信息, 这样的表示使得模型可以生成或预测 3D 场景的不同视角。本实施例从图像域 Ω 中均匀分布随机抽取图像块中心 $u \sim U(\Omega)$ 和图像块比例 $s \sim U([1, S])$, S 定义为如下公式:

$$S = \min(W, H) / K$$

其中, W 和 H 分别表示 PET 图像的宽和高。

因此, 在 2D 采样阶段, 如图 5 所示, 通过扫描过程的 2D 采样模式 \mathbf{v} 来采样 PET 图像在成像过程中 γ 光束 R 在一个 $K \times K$ 个图像块 P_{real} 内的点, 可以获得各点在 PET 成像场景中的尺度或深度信息。

S12: 利用下式定义射线采样过程中 $K \times K$ 的图像块 P_{real} 内的 2D 图像坐标 $P(u, s)$:

$$P(u, s) = \{(sx + u, sy + v) \mid x, y \in \{-\frac{K}{2}, \dots, \frac{K}{2} - 1\}\}。$$

S13: 如图 6 所示, 通过下式抽样 N 个沿着像素位置出发的 γ 光束 r 的 3D 点 \mathbf{x}_r^i , 并且

按照在各个平面的投影排序，以获得对于辐射场的数值积分。本实施例使用分层抽样方法，将 $[t_n, t_f]$ 分割成 N 个等距的区间，并从每个区间内均匀随机抽取一个样本；进而完成 3D 采样：

$$t_i \sim U[t_n + \frac{i-1}{N}(t_f - t_n), t_n + \frac{i}{N}(t_f - t_n)]$$

上式中， t_i 表示光束上的各个采样点； U 表示采样方式； t_n 和 t_f 分别表示近边界和远边界。

本实施例中，尽管使用了一组离散的样本来估计积分，但是分层抽样使其能够表示一个连续场景表示，这使得网络在优化过程中可以实现对连续位置进行评估。

S14: 经过上述 2D 采样和 3D 采样的过程，可以得到一系列三维坐标点。继续获取 PET 图像重建采用的传感器数据的传感器矩阵 K 和传感器姿态 ξ ，即可得到五维的点云数据。最终得到的点云数据包括三维空间坐标以及 K 和 ξ 。

S2: 将五维的点云数据降维成包含 3D 位置和角度信息的 2L 维数据，再利用预设的编码规则将 2L 维数据转换为包含密度标量 σ 和像素值 c 的 2 维数据。如图 7 所示，数据降维过程如下：

S21: 为了确保整个图像块在图像域 Ω 内。本实施例模拟解剖结构的形状和外观，用 z_s 表示形状编码，用于定义物体的三维结构； p_s 是形状编码的先验分布，为标准高斯分布，在没有其他信息的情况下，假定形状编码来自一个普通的、无偏差的随机分布。用 z_a 表示外观编码，决定了物体的表面特征，如颜色和纹理，在 PET 成像中则侧重于坐标点的强度； p_a 是外观编码的先验分布，也是标准高斯分布，为外观编码提供了一个无偏的起始点。让 $z_s \sim p_s$ 和 $z_a \sim p_a$ 作为从标准高斯分布采样的潜在编码。

S22: 在本实施例中，PET 成像被编码在网络模型中，并以 3D 位置 $\mathbf{v} = (\mathbf{u}, s)$ 和视角方向 $\mathbf{d} = (\theta, \phi)$ 作为输入，产生输出密度标量 σ 和像素值 c 。当用于 PET 成像，视角方向会结合 PET 成像的设定，以确保模型能够从正确的视角学习和预测医学图像中的密度和像素，这些方向参数可以由成像设备的物理配置或者是在数据预处理阶段从成像原始数据中提取得到。为了学习高频特征，输入被映射到一个如下的 2L 维的函数中：

$$\gamma(p) = \dots, \cos(2^j \pi p), \sin(2^j \pi p), \dots,$$

其中， $j = 0, \dots, m-1$ ， p 包括 3D 位置 x 和视角方向 d 。通过函数 $\gamma(p)$ 来表征 3D 采样的点云数据的 3D 位置 x 和视角方向 d ，进而得到位置函数 $\gamma(x)$ 和视角函数 $\gamma(d)$ 。

S23:，将 3D 空间中一个点的位置 x 和物体的形状编码 z_s 结合起来，生成一个中间变量 q ，即：

$$(\gamma(x), z_s) \mapsto q。$$

S24: 在中间变量 q 的基础上, 结合观察方向 d 和外观编码 z_a , 生成变量, 以预测最终的强度值 c , 即:

$$(q(x, z_s), \gamma(d), z_a) \mapsto c。$$

S25: 强度的预测不仅取决于 PET 成像的形状编码, 还取决于它的外观特性和传感器的位置与角度。用位置 x 和形状编码 z_s 生成的中间变量 q 来预测该位置的体素密度 σ , 即:

$$q(x, z_s) \mapsto \sigma。$$

本实施例中的体素密度决定了该点的实体或空洞程度, 对于创建 3D 模型和渲染图像非常重要。

在图 7 所示的编码过程中, 最终像素响应 c_r 可以通过以下公式计算得到:

$$\begin{aligned}\alpha_r^j &= 1 - \exp(-\alpha_r^i \delta_r^i) \\ \delta_r^j &= \|x_r^{i+1} - x_r^i\|_2 \\ c_r &= \sum_{i=1}^N c_r^i \alpha_r^i \exp\left(-\sum_{j=1}^{i-1} \sigma_r^j \delta_r^j\right)\end{aligned}$$

其中, α_r^j 是采样点 i 的 α 复合值, δ_r^i 是相邻采样点之间的距离。通过网络模型可以在光束 r 上的每个采样点处计算密度和像素值。最后, 结合所有光束的结果, 生成器 $G_\theta(z_s, z_a, \xi, \nu)$ 能够预测出图像块 P_{pred} 。

S3: 将编码阶段得到的 2 维数据与点云采样阶段得到的图像块 P_{real} 相互关联并作为样本数据, 利用包含大量样本数据的样本数据集对一个生成对抗网络进行训练, 得到一个可以根据 2 维数据生成任意视角下的图像块 P_{real} 的网络模型。

本实施例选择的生成对抗网络可以通过自监督学习实现对 PET 图像的高保真度合成。自监督学习使鉴别器 D_θ 学习到丰富的特征图。这些特征图更全面地覆盖了来自数字重建 PET 图像的信息, 从而为生成器 G_θ 提供了更好的训练信号。

本实施例采用基于自编码的方法, 使用两个解码器对不同尺度的特征图进行解码: f_1 在 32^2 尺寸上, f_2 在 128^2 尺寸上。使用学习的感知图像块相似度 (Learned Perceptual Image Patch Similarity, LPIPS) 指标评估从 D_θ 解码的图像块的全局结构。通过计算了两个特征空

间之间的加权重对图像距离，其中预训练的权重被调整以更好地匹配 3D 感知判断。因此，额外的鉴别器损失 L_r 如下：

$$L_r = E_{f \sim D(p), p \sim P} \left[\frac{1}{whd} \phi_i(G(p)) - \phi_i(T(p)) \right]$$

其中， ϕ_i 表示预训练的深度学习神经网络的第 i 层输出， w, h, d 分别代表一个特征空间的宽度、高度和深度， G 是 D_ϕ 对中间特征图 f 的处理，而 T 是对真实图像块 p 的处理。 $D(p)$ 表示解码图像块的分布， P 是真实图像数据的分布。 $E_{f \sim D(p), p \sim P}$ 表示对于从 $D(p)$ 和 P 中采样得到的 f 和 p 的期望。

当与这种额外的重建损失相结合时，网络模型学习了不同任务之间转移的表示。

此外，本实施例还利用数据增强来提升网络模型的学习效果，通过采用针对 GAN 优化的数据增强（Data Augmentation Optimized for GAN, DAG）框架来改善生成器 G_θ 和鉴别器 D_ϕ 的学习。框架中应用的数据增强转换 T_k 具有保持 JS 散度（Jenssen-Shannon Divergence）的特性，即它是一种不改变原始分布之间相对差异的数据增强方法，具体公式如下：

$$JS(p_d^{T_k} \parallel p_g^{T_k}) = JS(p_d \parallel p_g)$$

上式中， $p_d^{T_k}$ 是变换后的训练数据分布， $p_g^{T_k}$ 是由生成器经过相同增强变换后捕获的分布；， p_d 是原训练数据分布， p_g 是由生成器捕获的分布。

在本实施例构建的网络模型中，使用多个鉴别器头 $\{D_k\}$ 并共享 D_ϕ 除了与每个头对应的最后一层的所有层，以减少内存使用。此外，使用带权共享的多个鉴别器可以为 D_ϕ 的学习提供规则化。由此，定义总体损失函数如下：

$$f(u) = \max(0, 1 + u)$$

$$L(\theta, \{\phi_k\}) = L(\theta, \phi_0) + \frac{\lambda}{n-1} \sum_{i=1}^k L(\theta, \phi_k)$$

$$L(\theta, \phi_k) = E_{z_s \sim p_s, z_a \sim p_a, \xi \sim p_\xi, v \sim p_v} [f(D_\phi(G_\theta(z_s, z_a, \xi, v)))] + E_{I \sim p_D, v \sim p_v} [f(-D_\phi(I, v))] + L_r$$

上式中， I 表示真实图像； $\phi_i(\cdot)$ 表示预训练的深度学习神经网络的第 i 层输出；其中的网络可以是基于 CNN, Transform, Swin-Transformer, ConvNeXt 等模型的深度学习神经网络。

S4: 获取受试者 PET 扫描时重建出的有限的 PET 图像，将其依次进行采样和编码后转换为 2 维数据，然后输入到经过训练的生成对抗网络中，根据生成对抗网络生成的数据对检查部位进行体积渲染，并由生成器生成指定的任意视角下的新 PET 图像。

本实施例中，为了在模糊度和准确性之间取得平衡，通过添加均方误差（Mean Square Error, MSE）损失来修改网络模型的生成目标，并与负对数似然损失（Negative Log-likelihood

loss,NLLL) 结合, 定义损失函数如下:

$$L_{MSE}(G) = \frac{1}{N} \sum_{i=1}^N (I_i - G_i)^2$$

$$L_{NLLL}(z_s, z_a) = -\frac{1}{N} \sum_{i=1}^N \log p(p_s|z_s, p_a|z_a)$$

$$L_{gen} = \lambda_1 L_r(Net) + \lambda_2 L_{MSE}(G) + \lambda_3 L_{NLLL}(z_s, z_a)$$

$L_r(Net)$ 为与选取的深度学习神经网络有关模型损失, $L_{MSE}(G)$ 为生成器的均方误差损失; $L_{NLLL}(z_s, z_a)$ 为负对数似然损失; λ_1 、 λ_2 和 λ_3 分别为各类损失的权重; I_i 表示第 i 个真实图像; G_i 表示第 i 个生成图像。

最后, 通过不断迭代, 使模型找到 z_s 和 z_a 的最佳组合, 用它们渲染任意其余角度的 PET 图像投影, 即 3D 感知。

实施例 3

在实施例 1 和 2 的基础上, 本实施例还提供一种 PET 数据处理设备, 该数据处理设备采用如实施例 1 中的基于先验图像的 PET 图像重建方法, 利用受试者的 PET 扫描数据重建对应的 PET 图像。

该 PET 数据处理设备还可以采用如实施例 2 的基于神经辐射场的 PET 图像 3D 感知方法, 结合 PET 扫描数据和重建出的部分视角下 PET 图像生成指定的任意视角下的新的 PET 图像, 进而实现 3D 感知。其中, 重建出的部分视角下 PET 图像既可以是采用实施例 1 中的方案得到, 也可以是采用其他方案生成的。如传统的 FBP, MLEM, OSEM 等图像重建方案。

本实施例提供的 PET 数据处理设备本质上是一种用于实现数据处理和指令生成的计算机设备, 其包括存储器、处理器以及存储在存储器上并可在处理器上运行的计算机程序。本实施例中提供的计算机设备可以是安装在数控机床上的嵌入式设备, 也可以是独立与机床的能够执行计算机程序的智能终端、平板电脑、笔记本电脑、台式计算机、机架式服务器、刀片式服务器、塔式服务器或机柜式服务器(包括独立的服务器, 或者多个服务器所组成的服务器集群)等。本实施例的计算机设备至少包括但不限于: 可通过系统总线相互通信连接的存储器、处理器。

本实施例中, 存储器(即可读存储介质)包括闪存、硬盘、多媒体卡、卡型存储器(例如, SD 或 DX 存储器等)、随机访问存储器(RAM)、静态随机访问存储器(SRAM)、只读存储器(ROM)、电可擦除可编程只读存储器(EEPROM)、可编程只读存储器(PROM)、磁性存储器、磁盘、光盘等。在一些实施例中, 存储器可以是计算机设备的内部存储单元, 例如该计算机

设备的硬盘或内存。

在另一些实施例中，存储器也可以是计算机设备的外部存储设备，例如该计算机设备上配备的插接式硬盘，智能存储卡(Smart Media Card，SMC)，安全数字(Secure Digital，SD)卡，闪存卡(Flash Card)等。当然，存储器还可以既包括计算机设备的内部存储单元也包括其外部存储设备。本实施例中，存储器通常用于存储安装于计算机设备的操作系统和各类应用软件等。此外，存储器还可以用于暂时地存储已经输出或者将要输出的各类数据。

处理器在一些实施例中可以是中央处理器(Central Processing Unit，CPU)、图像处理器GPU(Graphics Processing Unit)、控制器、微控制器、微处理器、或其他数据处理芯片。该处理器通常用于控制计算机设备的总体操作。本实施例中，处理器用于运行存储器中存储的程序代码或者处理数据。

利用本实施例提供的PET数据处理设备后，用户进行PET检查的过程如下：

(一) 用户在医技人员的指导下，按照标准的姿势接受前端设备的扫描，完成PET检查。

(二) 后端的PET数据处理设备调取系统中患者原有的PET图像作为先验，若患者第一次进行PET扫描，可以采用由假体得到的样本图像作为先验。

(三) 将本次PET扫描获得大量传感器数据送入采用实施例1方案构建的基于先验图像的PET图像重建网络中，获得高分辨低噪声PET成像，供医生和病患参考。

(四) 将用户此次PET扫描图像保存在系统中，作为下次扫描的先验。

(五) 结合用户每次检查获得若干PET图像，采用基于实施例2方案构建的网络模型中，结合神经辐射场和生成对抗网络的基础，实现根据有限的PET图像进行3D感知生成。

(六) 医生通过上述PET图像重建和3D感知的结果获得任意角度的PET图像细节，进而辅助诊疗。

考虑到本实施例的PET数据处理设备改进了既有的图像重建和3D感知的算法，并具有在低传感器数据规模的条件下得到高质量的PET图像和3D感知的性能，因此该PET数据处理设备支持缩短扫描时间和辐射剂量已获得更稀疏的数据。该方案不仅适用于如图8所示的传统的环形传感器布局的PET设备，可以适用于如图9所示的平行板布局的PET设备。其中，与图8设备相比，图9中的设备成本更低，且在使用时对用户健康的伤害更小。

以上所述仅为本发明的较佳实施例而已，并不用以限制本发明，凡在本发明的精神和原则之内所作的任何修改、等同替换和改进等，均应包含在本发明的保护范围之内。




图 1

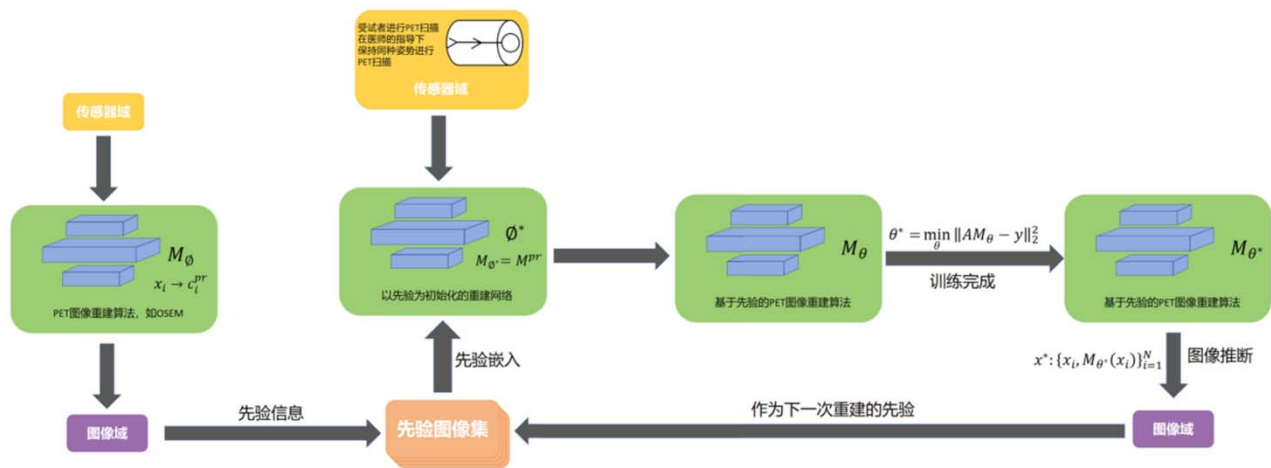


图 2

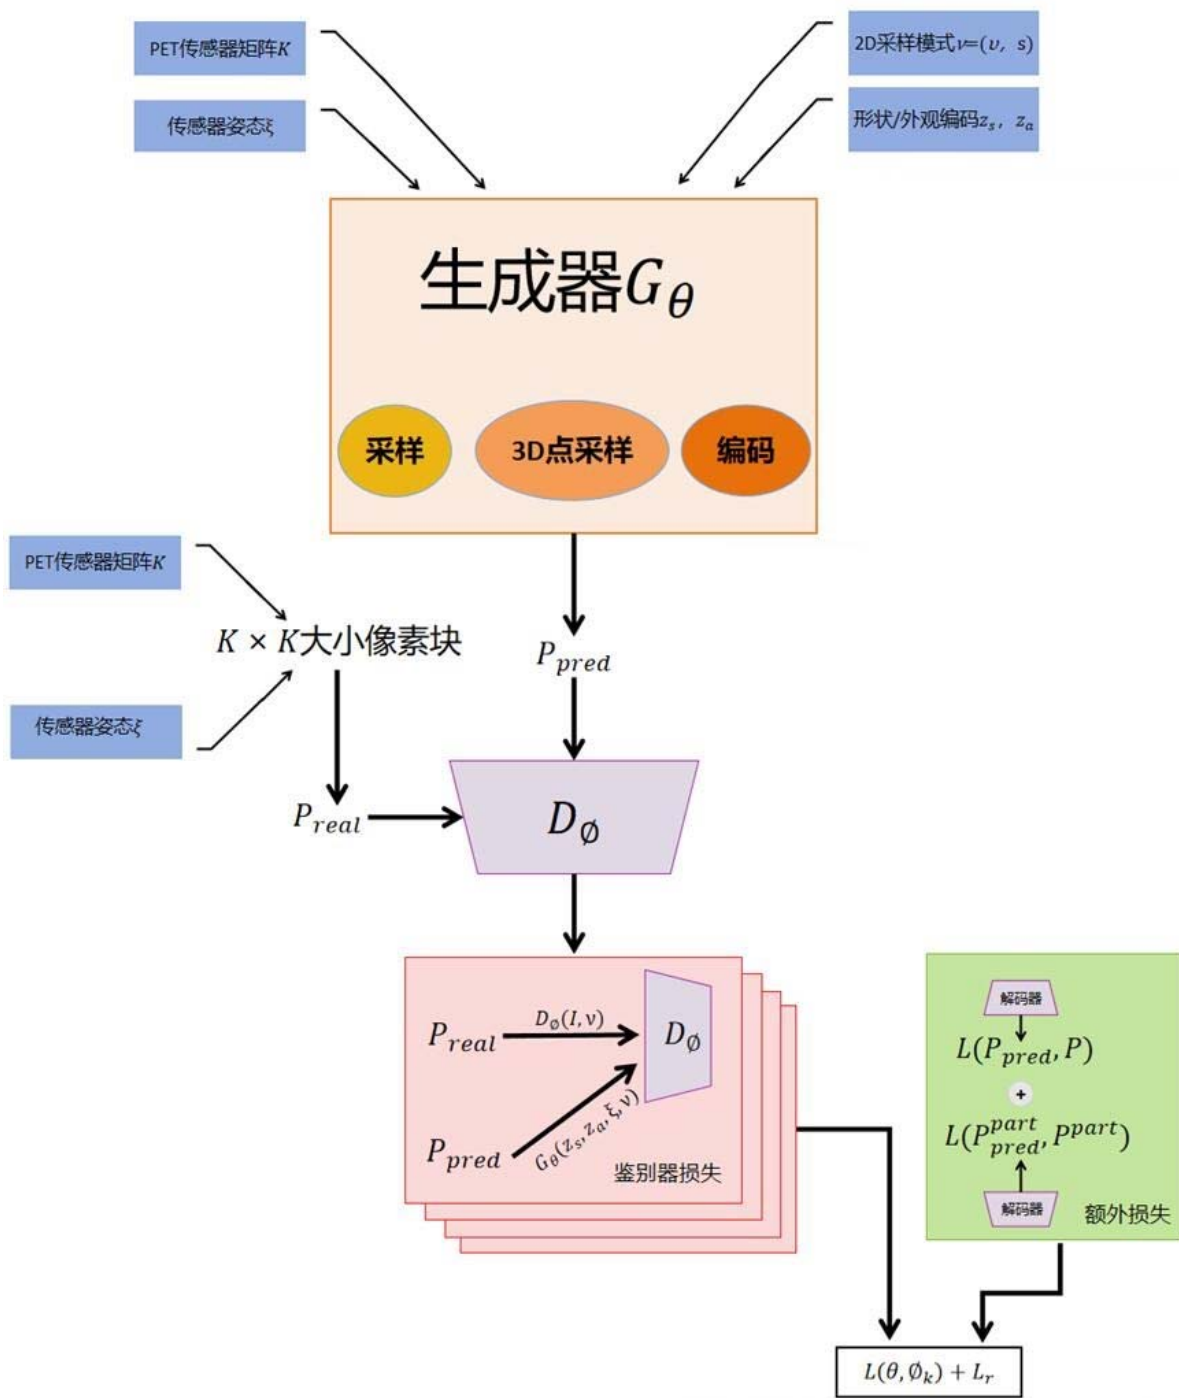


图 3

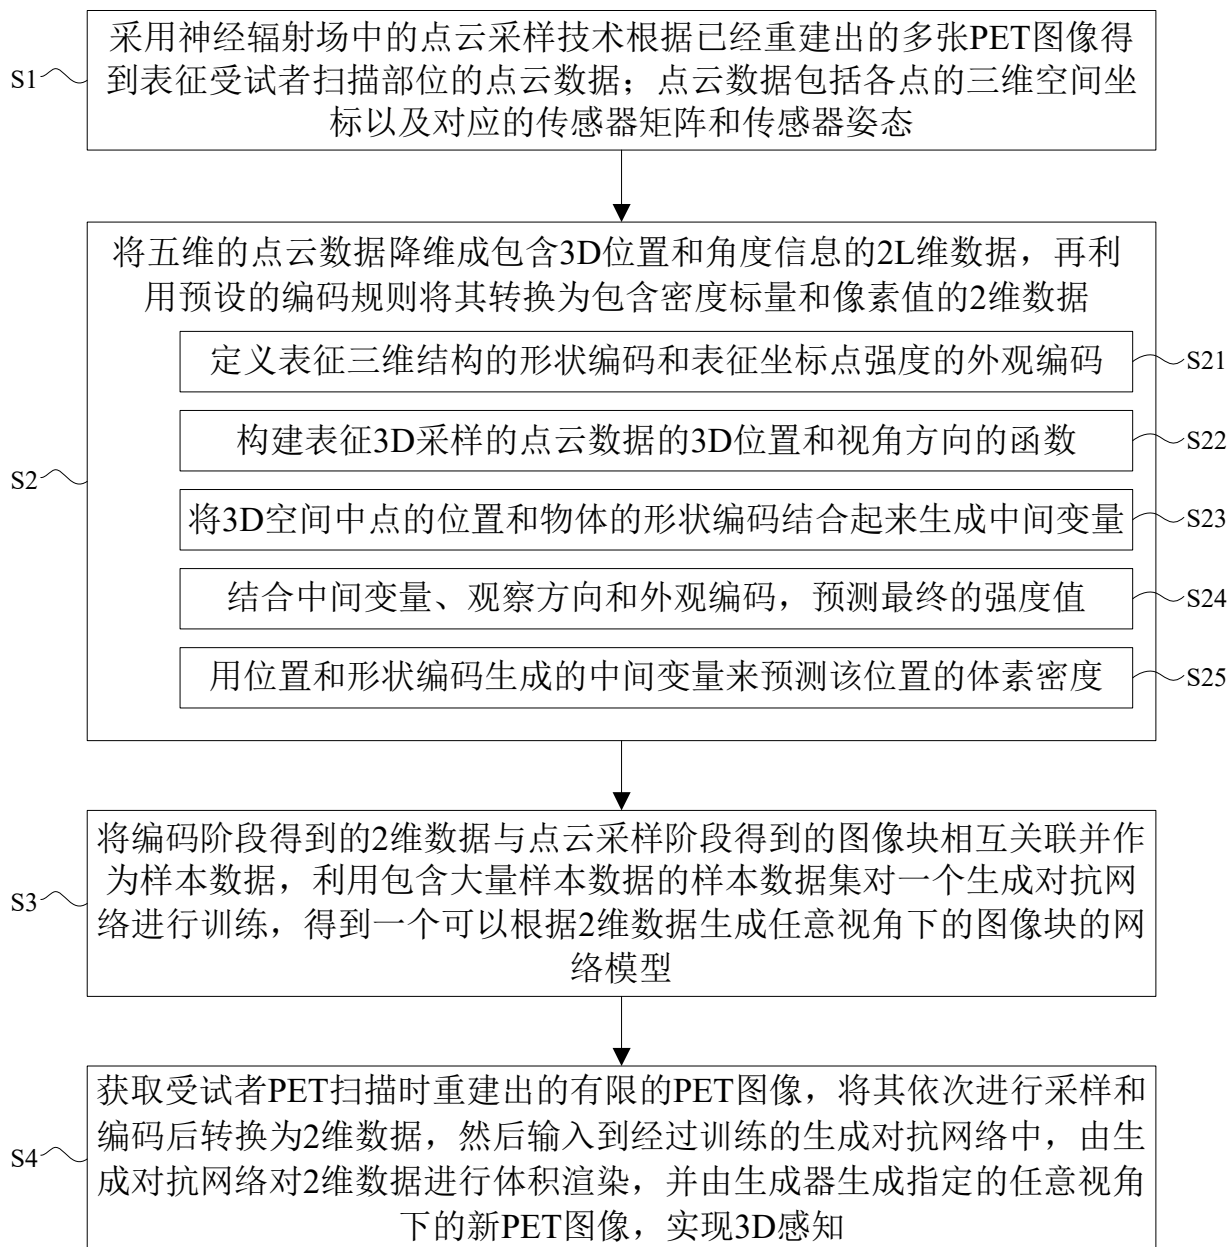


图 4




图 5




图 6

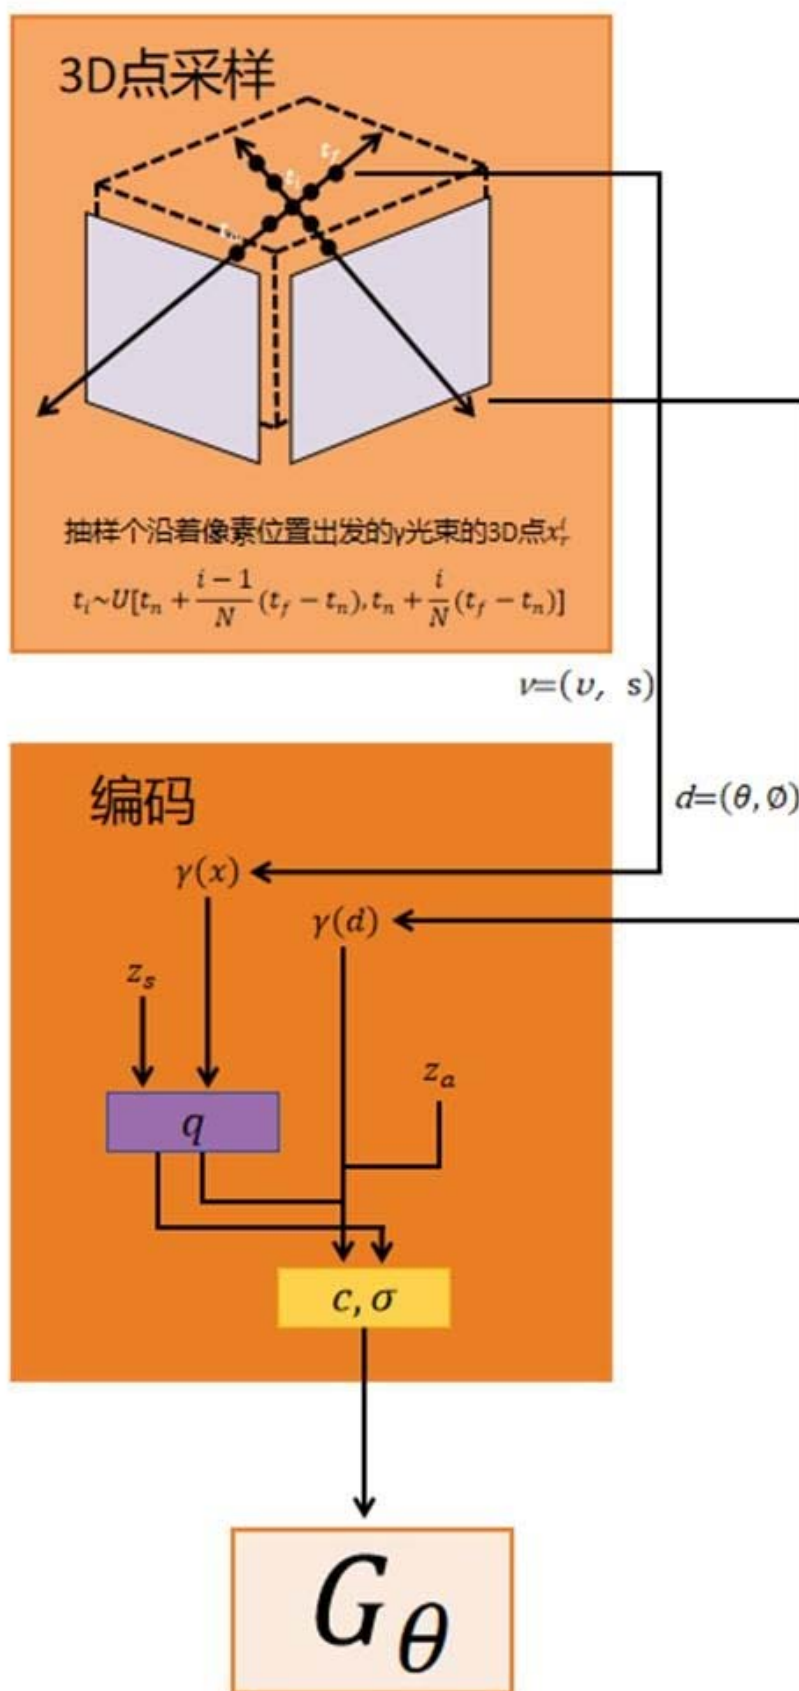


图 7




图 8




图 9